

AUDIT KUALITAS DATA

Pembagian Tugas untuk Tim

3 anggota, 3 dimensi audit paralel, 1 konvergensi keputusan. Memastikan dataset 127 puskesmas siap untuk pipeline ABSA dan EDA mendalam.

RANCANGAN PEMBAGIAN TUGAS

Tahap: Setelah Konsolidasi Master Dataset

Estimasi: 1 hari kerja terdistribusi

v1.0

SEC Satria Data 2026

OVERVIEW

Filosofi & Struktur

Setelah konsolidasi 127 puskesmas (Bantul 27, Surabaya 63, Semarang 37) menjadi satu master dataset, tahap berikutnya adalah **audit kualitas data** sebelum dilanjutkan ke EDA mendalam atau pipeline ABSA. Tahap ini sering luput tim pemula — mereka langsung lompat ke modeling, lalu menemukan masalah data di akhir, yang sudah terlambat untuk diperbaiki.

Audit kualitas tidak paralel-friendly secara penuh. Banyak temuan di satu audit memengaruhi audit lain — misalnya, kalau ditemukan banyak teks non-Indonesia, keputusan drop/keep memengaruhi distribusi rating yang sedang dilihat orang lain. Strategi pembagian: **paralel di pekerjaan, sinkron di decision-making**.

Tiga Dimensi Audit

	Anggota A	Anggota B	Anggota C
Dimensi	Integritas Struktural	Karakteristik Konten	Sinyal Substantif
Pertanyaan	"Apakah data ini reliable?"	"Apakah datanya layak diproses?"	"Apa yang dataset ini bisa ceritakan?"
Output utama	Data quality report + cleaning rules	Content profile + filter rules	Initial findings + flagged samples
Estimasi waktu	3-4 jam	4-5 jam	4-5 jam

***Aturan emas:** Audit ini hanya menghasilkan proposal rules. Eksekusi cleaning baru dilakukan setelah konvergensi meeting tim. Jangan ada satu anggota yang sepihak menghapus data, walau merasa yakin.*

ANGGOTA A

Audit Integritas Struktural

ANGGOTA A

Audit Integritas Struktural

Fokus: Memastikan dataset bisa dipercaya secara teknis

Pertanyaan inti: *Apakah data ini reliable?*

Output utama: Folder data_quality/ dengan ~6 file CSV/MD

Daftar Tugas

A1 — Verifikasi konsolidasi

Cek bahwa master dataset hasil konsolidasi tepat dan lengkap.

- Buka puskesmas_summary.csv: total puskesmas = 127?
- Per wilayah: Bantul 27, Surabaya 63, Semarang 37?
- Tidak ada puskesmas dengan n_reviews = 0? (kalau ada, investigasi file aslinya)

Output: Confirmation report, 1 paragraf

A2 — Audit identitas puskesmas

Pastikan nama puskesmas dari nama file match dengan title yang ter-scrape dari Google Maps.

- Manual check 20 sample: apakah puskesmas_name match dengan puskesmas_title?
- Untuk Surabaya CamelCase: cek auto-split benar? (misal DrSoetomo → 'Dr Soetomo' mungkin perlu fix manual)
- Catat semua mismatch ke list

Output: data_quality/identity_mismatches.csv

A3 — Audit duplicate

Identifikasi pola duplikasi yang lebih dari sekadar exact-text-match.

- Same reviewer + same puskesmas + multiple reviews dalam waktu dekat (jika ada kolom tanggal)
- Different reviewer dengan teks identik (copy-paste atau bot)
- Duplicate review_url

Output: data_quality/duplicate_findings.csv

A4 — Audit kelengkapan

Hitung missing rate per kolom dan per wilayah.

- Count missing untuk rating, review_text, reviewer_name, dst
- Distribusi per wilayah: ada wilayah dengan missing rate jauh lebih tinggi?

Output: data_quality/completeness_report.csv

A5 — Audit temporal

Jika ada kolom tanggal: cek coverage temporal per puskesmas.

- Range tanggal per puskesmas
- Puskesmas dengan ulasan terakhir > 1 tahun lalu (data stale)
- Lonjakan volume di waktu tertentu (kemungkinan event)

Output: Temporal coverage report (jika tanggal tersedia)

A6 — Decision: cleaning rules draft

Berdasarkan A1-A5 dan A7 (anomali kreatif di bawah), draft cleaning rules untuk diskusi tim.

- Threshold n_reviews minimum
- Handling missing rating: drop / impute / keep?
- Rules untuk handle duplicate suspicious

Output: data_quality/cleaning_rules_proposal.md

A7 — Anomali Kreatif (Bagian Inti)

Ini bagian paling penting dari audit Anggota A. Cari pola-pola yang **tidak akan terdeteksi tools otomatis** tapi sering muncul di dataset scraping publik. Temuan di sini akan menjadi *integrity discussion* yang berharga di esai.

Pertanyaan inti A7: "Apa yang terlihat aneh kalau aku zoom in?" Bukan pencarian pasti, tapi investigasi rasa ingin tahu.

Kategori 1 — Internal Inconsistency

Dua kolom di baris yang sama saling kontradiktif. Pattern: logika harus konsisten dalam 1 row.

- `is_empty_text=True` tapi `text_length > 0` (whitespace karakter? null vs empty string?)
- `text_length = 0` tapi `review_text` bukan NaN
- `rating` ada tapi `review_text` null (rating-only review)
- `review_text` ada tapi `rating` null (scraping miss?)
- `reviewer_name` null tapi `review_text` ada (anonymous?)
- `text_length` di summary tidak match dengan actual character count

Kategori 2 — Distribusi (Statistical Outliers)

Distribusi nilai per puskesmas yang menyimpang dari ekspektasi statistik.

- Puskesmas dengan **std rating = 0** — semua ulasan rating sama (suspicious)
- Puskesmas dengan **rating bimodal ekstrem** — 95% rating 5 + 5% rating 1
- Puskesmas dengan jumlah ulasan jauh > **99th percentile wilayah**
- Puskesmas dengan median `text_length` sangat rendah (semua ulasan cuma 'bagus'/'jelek')
- Wilayah dengan distribusi rating sangat berbeda dari wilayah lain

Kategori 3 — Duplicate Patterns (Beyond Exact)

Tidak persis sama, tapi mencurigakan mirip. Pattern: bot detection, fake reviews.

- Same reviewer review banyak puskesmas dengan teks template ('Pelayanan baik', 'Pelayanan baik', ...)
- Different reviewer, near-duplicate text (Levenshtein distance kecil) — variant bot
- Many reviews dari reviewer dengan `total_reviews = 0` atau 1 (akun fake?)
- Reviewer cluster — banyak nama mirip pattern ('user123', 'user124', ...)
- Same `review_id` muncul lebih dari sekali (scraping error)

Kategori 4 — Reviewer Behavior

- Reviewer dengan rating uniform ekstrem (selalu 5 atau selalu 1 di banyak puskesmas)
- Reviewer name yang generic ('Anonim', 'user', 'pengguna google')
- Same reviewer name muncul di banyak puskesmas berbeda — verify orang sama atau cluster?

Kategori 5 — Encoding & Format

Data secara teknis ada tapi rusak. Bisa menyebabkan downstream error di NLP.

- Encoding artifacts: karakter seperti `â€™`, `Ã©` (mojibake)
- HTML entities tidak ter-decode: `&`, `"`, `'`
- Excessive whitespace: ' ' dianggap teks tapi kosong konten
- Tab/newline characters dalam text (bisa merusakkan CSV nanti)
- Text yang isinya cuma emoji (ABSA tidak bisa proses)
- Text yang isinya cuma punctuation ('!!!', '???')
- `rating` sebagai string ('5 stars') bukan numeric

Kategori 6 — Cross-File Identity

- puskesmas_title mengandung nama wilayah lain (false-match scraping)
- Multiple puskesmas_id punya puskesmas_title identik (duplicate data)
- puskesmas_url sama di puskesmas berbeda (wrong scraping link)

Bonus task untuk A: Jika menemukan anomali yang menarik (misal: "Puskesmas X punya 15 reviewer dengan total_reviews=0 dan semuanya rating 5 dalam 2 minggu"), dokumentasikan sebagai **case study**. Ini bisa jadi integrity discussion yang berharga di esai — bukti bahwa tim sadar limitasi data publik.

ANGGOTA B

Audit Karakteristik Konten

ANGGOTA B

Audit Karakteristik Konten

Fokus: Memahami apakah teks ulasan layak untuk ABSA

Pertanyaan inti: *Apakah datanya layak diproses?*

Output utama: Folder data_quality/ dengan content audit files

Daftar Tugas

B1 — Audit bahasa

Klasifikasi bahasa ulasan untuk menentukan filtering.

- Sample 200 ulasan random
- Klasifikasi: Indonesia formal / gaul / campuran bahasa daerah / bahasa asing / mixed
- Hitung proporsi per kategori
- Tool: pakai langdetect library untuk auto-detect, lalu manual verify
- Note handling: drop atau retain dengan flag?

Output: data_quality/language_audit.csv dengan sample + klasifikasi

B2 — Audit panjang teks

Distribusi text_length dengan qualitative inspection di tail.

- Distribusi text_length dari master file
- Ultra short (< 20 char): berapa banyak? Sample 30 dan baca — '■', 'Bagus', 'Mantap'? Worthwhile?
- Very long (> 1000 char): sample 10 dan baca — review-essay yang insightful?

Output: Distribusi length + sample qualitative

B3 — Audit content quality

Apakah teks mengandung aspek konkret yang bisa di-ABSA?

- Sample 50 ulasan dengan panjang 50-500 char (sweet spot ABSA)
- Klasifikasi: mengandung aspek konkret (dokter/antrean/obat/dll), sentimen-only tanpa aspek, atau off-topic?
- Hipotesis yang dicari: berapa persen ulasan yang bisa di-ABSA secara meaningful (estimated yield rate)?

Output: Content quality classification + estimated yield rate

B4 — Audit noise patterns

Pola-pola yang akan menyulitkan ABSA model.

- Emoji-heavy reviews (banyak emoji, sedikit teks)
- All-caps reviews
- Repeated character ('baguuuusss bangettt')
- Multiple aspect dalam satu kalimat panjang (perlu sentence splitting?)
- Sarkasme (manual hunting di rating 1-2)

Output: Noise pattern catalog dengan contoh

B5 — Audit sentiment-rating consistency

Apakah rating dan teks konsisten?

- Sample 50 ulasan rating 5 → konsisten positif?
- Sample 50 ulasan rating 1 → konsisten negatif?
- Sample 50 ulasan rating 3 → mixed atau netral?
- Cari mismatch: rating tinggi tapi teks komplain (atau sebaliknya) — insight menarik sekaligus noise

Output: Rating-text consistency report

B6 — Decision: filter rules draft

Berdasarkan B1-B5, draft filter rules.

- Minimum text length untuk ABSA?
- Handling non-Indonesia: drop / keep with flag?
- Bagaimana handle rating-text mismatch?

Output: data_quality/filter_rules_proposal.md

ANGGOTA C

Audit Sinyal Substantif

ANGGOTA C

Audit Sinyal Substantif

Fokus: Mulai mendeteksi cerita yang ada di dataset

Pertanyaan inti: *Apa yang dataset ini bisa ceritakan?*

Output utama: Folder eda/ dengan visualisasi awal + bank kutipan

Daftar Tugas

C1 — Distribusi rating per wilayah

Apakah Bantul, Surabaya, Semarang punya pola rating berbeda?

- Histogram rating untuk masing-masing wilayah
- Mean, median, std per wilayah
- Cari outlier wilayah: ada satu yang jauh lebih kritis atau permisif?

Output: eda/rating_distribution_by_wilayah.png + *interpretasi 1 paragraf*

C2 — Ranking puskesmas

Identifikasi puskesmas paling menonjol untuk analisis lebih dalam.

- Top 10 rating tertinggi (filter `n_reviews ≥ 30`)
- Bottom 10 rating terendah (filter `n_reviews ≥ 30`)
- Mid 10 dengan std tertinggi — puskesmas paling polarized (banyak puas DAN banyak kecewa)

Output: eda/puskesmas_rankings.csv

C3 — Manual reading: top sample

Membangun bank kutipan untuk esai.

- Untuk top 3, bottom 3, polarized 3 (total 9 puskesmas):
- Baca 5-10 ulasan random per puskesmas
- Catat 2-3 kutipan menarik per puskesmas (kalimat konkret untuk contoh esai)

Output: eda/qualitative_excerpts.md — *bank kutipan*

C4 — Keyword analysis (TF-IDF)

Identifikasi sinyal linguistik antara rating positif vs negatif.

- Vectorize corpus dengan TF-IDF
- Top-20 kata khas di rating 1-2 vs rating 4-5
- Hipotesis: *Negatif:* 'lama', 'antri', 'tidak ramah', 'habis', 'tutup'. *Positif:* 'ramah', 'cepat', 'bersih', 'telaten', 'memuaskan'

Output: eda/keyword_signals.csv

C5 — Volume vs Rating relationship

Apakah popularitas berbanding terbalik dengan rating?

- Scatter plot: x = jumlah ulasan per puskesmas, y = rating mean
- Hipotesis: puskesmas dengan banyak ulasan cenderung punya rating lebih rendah (visibility effect)?

Output: eda/volume_vs_rating.png + interpretasi

C6 — Initial findings document

Konsolidasi C1-C5 jadi narasi awal untuk esai.

- 3 fakta paling menarik dari dataset
- 3 cerita potensial untuk esai (puskesmas atau pattern yang menonjol)
- 3 pertanyaan yang belum bisa dijawab (untuk EDA mendalam berikutnya)

Output: eda/initial_findings.md

TIMELINE

Hari Kerja Terdistribusi

Timeline ini bukan kaku — sesuaikan dengan tempo tim. Yang penting: **dua sync meeting wajib**, satu di tengah hari (sharing temuan awal) dan satu di akhir (konvergensi keputusan).

Waktu	Anggota A	Anggota B	Anggota C
Pagi 3 jam	A1, A2, A3	B1, B2	C1, C2
Sync 1 30 menit	Share temuan awal — apa kejutan terbesar sejauh ini?		
Siang 3 jam	A4, A5, A7 (kreatif!)	B3, B4	C3, C4
Sore 1 jam	A6 — draft rules	B5, B6 — draft rules	C5, C6 — findings
Sync 2 1 jam	Konvergensi keputusan		

Agenda Sync Meeting 2 (Konvergensi)

Bagian	Durasi	Konten
1. Cleaning rules	20 menit	A dan B presentasikan proposal. Tim diskusi & vote. C catat keputusan ke FINAL_cleaning_rules.md
2. Sample story	25 menit	C presentasikan initial findings + qualitative excerpts. Tim diskusi: cerita mana yang paling berpotensi untuk esai? Catat 2-3 angle untuk dikejar.
3. Next steps	15 menit	Distribusi tugas berikutnya (cleaning execution + deep EDA). Setup deadline.

Risiko Paralel — Yang Harus Diwaspadai

Risiko	Mitigasi
Trio menemukan masalah saling terkait A menemukan duplikat suspicious, B menemukan emoji-heavy, C menemukan bimodal — ketiganya bisa terkait	Di sync meeting, eksplisit cross-reference temuan. Mungkin satu reviewer di satu puskesmas adalah akar masalah ketiga
Decision premature A buat keputusan drop ulasan < 20 char. B menemukan ulasan 15 char yang valuable.	Draft rules, jangan eksekusi sampai meeting. Rules proposal saja, execution setelah sepakat
C bangun story yang tidak didukung data quality C excited dengan 'Puskesmas X polarized', tapi A menemukan banyak duplikat di puskesmas itu — story rapuh	C harus re-check findings dengan filtered data di iterasi berikutnya. Initial findings adalah hipotesis, bukan kesimpulan

CLOSING

Definition of Done

Sebelum tutup hari, harus ada:

File	Berisi	Pemilik
data_quality/ FINAL_cleaning_rules.md	Keputusan tim — rules disepakati semua anggota, tidak ada yang sepihak	A + B + C
data/master/ reviews_cleaned.csv	Dataset setelah cleaning rules diterapkan	A (executor)
eda/initial_findings.md	3 cerita potensial + 3 pertanyaan untuk EDA mendalam	C
eda/qualitative_excerpts .md	Bank kutipan menarik untuk esai	C
data_quality/ anomaly_findings.md	Temuan kreatif A7 — pattern yang menarik untuk integrity discussion di esai	A

Tools yang Dibutuhkan

- **pandas** — manipulasi DataFrame
- **matplotlib / seaborn** — visualisasi distribusi
- **langdetect** — auto-detect bahasa untuk Anggota B (`pip install langdetect`)
- **sklearn** — TF-IDF untuk Anggota C
- **fuzzywuzzy / python-Levenshtein** — near-duplicate detection untuk Anggota A (opsional, `pip install fuzzywuzzy python-Levenshtein`)

Penutup

Audit kualitas sering dianggap pekerjaan kotor — kerja yang tidak terlihat di output akhir. Tapi tim esai yang menang biasanya yang **kenal datanya luar dalam** sebelum menulis. Saat juri bertanya "Bagaimana dengan ulasan palsu?" atau "Apakah data merata?", tim kamu sudah punya jawaban karena sudah audit sebelumnya. Anomaly kreatif Anggota A khususnya — itu yang membedakan tim yang "asal pakai data publik" dengan tim yang "benar-benar memahami limitasi datanya". Yang kedua selalu lebih kredibel di mata juri statistika.