



## STATISTICS ESSAY COMPETITION

### SATRIA DATA 2025

Universitas Islam Indonesia

## NEET2Next: Aplikasi Berbasis *Machine Learning* untuk Prediksi Peluang Karier dan Personalisasi Pembelajaran sebagai Strategi Pengurangan Angka NEET

### Ketimpangan Sosial dan Ekonomi

*Akses terhadap Pendidikan dan Peluang Ekonomi: Data sebagai Alat Pengukur  
Keadilan*

SEC\_SD2025020000075

## 1. Pendahuluan

### 1.1. Latar Belakang

Masa depan bangsa ditentukan oleh sejauh mana anak dan pemuda memperoleh kesempatan untuk mengembangkan kapasitasnya (Bronfenbrenner, 1979). Namun, Indonesia masih menghadapi tantangan struktural, salah satunya tingginya jumlah pemuda dalam kategori *Not in Education, Employment, or Training* (NEET), yaitu individu berusia 15–24 tahun yang tidak bekerja, bersekolah, atau mengikuti pelatihan (ILO, 2017). Data Badan Pusat Statistik (BPS) menunjukkan bahwa pada 2024 persentase NEET mencapai titik terendah dalam satu dekade terakhir, yakni sebesar 20,31%, tetapi capaian tersebut belum sepenuhnya menggambarkan kondisi aktual pasar tenaga kerja dan pendidikan di Indonesia. CNBC Indonesia (Juni 2025) melaporkan bahwa tingkat pengangguran *fresh graduate* sebesar 4,8%, lebih tinggi dibandingkan tingkat



DIKTISAINTEK  
BERDAMPAK



pengangguran nasional sebesar 4,0%. Dari sisi pendidikan, angka putus sekolah tertinggi berada di jenjang SMK (0,19%) dan SMA (0,13%) (Kemendikdasmen, 2024/2025).

Menurut *Indonesia Labour Market Profile* (2025), persentase NEET pada 2023 mencapai 21% dengan proporsi pemuda (26%) lebih tinggi daripada pemuda (17%) serta kerentanan yang lebih besar pada kelompok berpenghasilan rendah. Hal ini sejalan dengan temuan World Bank (2020) mengenai kerentanan pemuda miskin di pedesaan dan Pattinasarany (2024) yang menegaskan efek protektif kelas sosial terhadap risiko menjadi NEET. Kondisi ini menegaskan perlunya upaya terintegrasi, sejalan dengan Target 8.6 *Sustainable Development Goals* (SDGs) 2030 yang menargetkan pengurangan signifikan pemuda NEET.

## 1.2. Identifikasi Masalah

Meskipun tren NEET menunjukkan penurunan, distribusinya masih kompleks dan dipengaruhi faktor sosial-ekonomi, pendidikan, akses informasi, dan kesenjangan gender. Kondisi ini menciptakan kerentanan yang berbeda antarwilayah dan kelompok sosial, sementara kebijakan yang ada sering kali reaktif dan kurang didukung data detail. Pada tingkat individu, keterbatasan akses terhadap informasi, pelatihan, dan mentoring membuat pemuda NEET semakin sulit bertransisi ke pendidikan atau dunia kerja. Oleh karena itu, diperlukan pendekatan prediktif yang mampu mengantisipasi dinamika ke depan.

Pendekatan berbasis data menawarkan solusi dengan mengintegrasikan analisis spasial, temporal, dan metode statistika modern, seperti klasterisasi, peramalan, dan klasifikasi. Penelitian ini memperkenalkan NEET2Next, *platform* inovatif yang mengubah data mentah menjadi wawasan yang bisa ditindaklanjuti bagi pemerintah maupun individu. Fitur-fitur seperti pemetaan wilayah rawan NEET, proyeksi tren, rekomendasi lowongan, kursus keterampilan, hingga konsultasi mentor menjadikannya solusi integratif yang mendukung kebijakan berbasis data sekaligus membantu pemuda membangun masa depan lebih produktif.




DIKTISAINTEK  
BERDAMPAK



## 2. Pembahasan

### 2.1. Metode Analisis

Tahapan analisis data yang digunakan pada penelitian ini dijelaskan pada Gambar 1.



**Gambar 1.** Metode Analisis

#### 2.1.1. Data Collection

Penelitian ini menggunakan dua jenis data, yaitu data utama dan data pendukung. Data utama diperoleh dari Survei Angkatan Kerja Nasional (Sakernas) Februari 2025 yang dirilis oleh Badan Pusat Statistik. Sementara itu, data pendukung digunakan untuk mendukung analisis, mencakup Persentase Pemuda Berusia 15–24 Tahun yang Tidak Bersekolah, Bekerja, atau Mengikuti Pelatihan 2024, Tingkat Partisipasi Angkatan Kerja 2024, Tingkat Pengangguran Terbuka 2024, Produk Domestik Regional Bruto 2024, serta Persentase Melek Aksara 2024. Seluruh data pendukung tersebut juga bersumber dari BPS.

**Tabel 1.** Variabel Penelitian

| Variabel | Keterangan |
|----------|------------|
|----------|------------|



**DIKTISAINTEK  
BERDAMPAK**



|                                           |                                                                                            |
|-------------------------------------------|--------------------------------------------------------------------------------------------|
| Provinsi                                  | Provinsi tempat tinggal responden.                                                         |
| Bidang Pekerjaan Lama                     | Lapangan usaha (KBLI 2020) dari pekerjaan sebelumnya.                                      |
| Pernah Bekerja                            | Status pengalaman kerja responden (pernah atau tidak).                                     |
| Usia                                      | Usia responden (15–24 tahun).                                                              |
| Pendidikan Tertinggi                      | Jenjang pendidikan tertinggi yang ditamatkan responden.                                    |
| Jenis Kelamin                             | Jenis kelamin responden.                                                                   |
| Status <i>Training</i>                    | Status pernah mengikuti <i>training</i> /pelatihan/kursus.                                 |
| Bidang Target Pekerjaan                   | Lapangan usaha (KBLI 2020) yang diinginkan responden.                                      |
| Provinsi Target                           | Provinsi tempat kerja yang diinginkan responden.                                           |
| Persentase NEET                           | Proporsi pemuda usia 15–24 tahun yang tidak bersekolah, bekerja, atau mengikuti pelatihan. |
| Tingkat Partisipasi Angkatan Kerja (TPAK) | Persentase penduduk usia kerja yang masuk ke angkatan kerja (bekerja atau mencari kerja).  |
| Tingkat Pengangguran Terbuka (TPT)        | Persentase angkatan kerja yang tidak bekerja dan sedang aktif mencari pekerjaan.           |
| Produk Domestik Regional Bruto (PDRB)     | Nilai total barang dan jasa yang dihasilkan suatu daerah.                                  |



**DIKTISAINTEK  
BERDAMPAK**



|              |                                                                   |
|--------------|-------------------------------------------------------------------|
| Melek Aksara | Persentase penduduk usia tertentu yang mampu membaca dan menulis. |
|--------------|-------------------------------------------------------------------|

Data Sakernas Februari 2025 digunakan untuk membangun model prediksi berbasis *machine learning* dengan variabel target, yaitu bidang target pekerjaan. Variabel prediktornya meliputi provinsi, bidang pekerjaan lama, pernah bekerja, usia, pendidikan tertinggi, jenis kelamin, status *training*, dan provinsi target. Model ini bertujuan mengestimasi kecocokan pemuda, baik NEET maupun angkatan kerja muda, dengan bidang pekerjaan tertentu berdasarkan profil dan pengalaman sehingga menghasilkan rekomendasi karier yang lebih personal.

Selain itu, variabel persentase NEET dianalisis dengan dua pendekatan: (1) peramalan untuk memproyeksikan tren jangka panjang dan potensi risiko, serta (2) klasterisasi dengan indikator makro (TPAK, TPT, PDRB, melek aksara) guna mengelompokkan provinsi menurut karakteristik ekonomi-pendidikan. Integrasi klasifikasi, peramalan, dan klasterisasi ini diharapkan mampu memberikan rekomendasi karier individual sekaligus proyeksi makro dan pemetaan spasial yang bermanfaat bagi perumusan kebijakan.

### 2.1.2. Klasterisasi

Klasterisasi merupakan teknik *unsupervised learning* yang bertujuan untuk mengelompokkan data ke dalam klaster berdasarkan kemiripan karakteristiknya. Pada penelitian ini, metode klasterisasi yang digunakan adalah *K-Means*, *Agglomerative*, dan *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN). Algoritma *K-Means* membagi data ke dalam  $k$  klaster dengan meminimalkan variansi intraklaster melalui iterasi *centroid*. *Agglomerative* sebagai bagian dari *hierarchical clustering* menggunakan pendekatan *bottom-up* dengan setiap objek awalnya merupakan klaster tunggal dan secara bertahap digabungkan dengan klaster lain yang paling mirip sampai membentuk klaster besar. Sementara itu, DBSCAN mengelompokkan data berdasarkan kepadatan titik dalam suatu ruang sehingga mampu mengenali klaster dengan bentuk tidak beraturan serta mendeteksi *noise*. Untuk menilai performa, model dievaluasi menggunakan metrik berikut.

#### 2.1.2.1. Silhouette Score



*Silhouette Score* mengukur kemiripan dari suatu titik data di dalam kluster yang dibandingkan dengan kluster lainnya. Nilai *Silhouette Score* yang lebih tinggi menunjukkan hasil klusterisasi yang lebih baik. Persamaan yang digunakan adalah sebagai berikut:

$$s(i) = \frac{b(i) - a(i)}{\{a(i), b(i)\}} \quad (1)$$

dengan  $a(i)$  merupakan rata-rata jarak  $i$  ke semua titik kluster yang sama dan  $b(i)$  merupakan rata-rata jarak  $i$  ke semua titik kluster terdekat yang lain.

#### 2.1.2.2. *Davies-Bouldin Index (DBI)*

*Davies-Bouldin Index* mengevaluasi seberapa baik proses klusterisasi yang dilakukan berdasarkan variabel yang ada pada data yang digunakan. Nilai DBI yang lebih rendah menunjukkan klusterisasi yang lebih baik. Persamaan yang digunakan sebagai berikut:

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{i \neq j} R_{ij} \quad (2)$$

dengan  $R_{ij}$  merupakan rasio antara kluster  $i$  dan kluster  $j$ .

#### 2.1.2.3. *Calinski-Harabasz Index (CHI)*

*Calinski-Harabasz Index* mengukur rasio antara varian internal dalam setiap kluster dan varian antarkluster. Nilai CHI yang lebih tinggi menunjukkan bahwa klusterisasi yang lebih baik. Persamaan yang digunakan sebagai berikut:

$$CHI = \frac{Tr(B_k)}{Tr(W_k)} \times \frac{n - k}{k - 1} \quad (3)$$

dengan  $n$  merupakan jumlah data,  $Tr(B_k)$  merupakan *trace* dari matriks antarkluster, dan  $Tr(W_k)$  merupakan *trace* dari matriks dalam kluster.

#### 2.1.3. Peramalan



DIKTISAINTEK  
BERDAMPAK



Peramalan adalah proses memprediksi nilai periode selanjutnya menggunakan data historis. Pada penelitian ini, metode peramalan yang digunakan adalah *Holt Exponential Smoothing*, *Brown Exponential Smoothing*, dan *Autoregressive Integrated Moving Average* (ARIMA). *Holt Exponential Smoothing* dan *Brown Exponential Smoothing* digunakan pada data yang dipengaruhi oleh tren, tetapi tidak dipengaruhi oleh musim. Dalam melakukan peramalan, *Holt Exponential Smoothing* menggunakan dua parameter untuk pemulusan level dan estimasi tren. Sementara itu, *Brown Exponential Smoothing* hanya menggunakan satu parameter dari *brown*. *Autoregressive Integrated Moving Average* (ARIMA) adalah gabungan model *Autoregressive* (AR) dan *Moving Average* (MA). *Integrated* yang berordo  $d$  dilakukan jika data tidak stasioner dalam rata-rata. Untuk menilai performa, model dievaluasi menggunakan metrik berikut.

#### 2.1.3.1. Root Mean Square Error (RMSE)

*Root Mean Square Error* adalah perhitungan kesalahan dari nilai besarnya rata-rata galat pada data. RMSE dihitung menggunakan rumus sebagai berikut:

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (\hat{Y}_t - Y_t)^2} \quad (4)$$

dengan  $\hat{Y}_t$  merupakan nilai hasil peramalan dan  $Y_t$  merupakan nilai data aktual.

#### 2.1.3.2. Mean Absolute Error (MAE)

*Mean Absolute Error* menunjukkan rata-rata galat absolut antara hasil peramalan dengan nilai data aktual. Rumus MAE adalah sebagai berikut:

$$MAE = \frac{1}{n} \sum_{t=1}^n |\hat{Y}_t - Y_t| \quad (5)$$

#### 2.1.3.3. Mean Absolute Percentage Error (MAPE)

*Mean Absolute Percentage Error* dihitung dengan membagi galat absolut tiap periode dengan nilai aktual, kemudian merata-ratakan hasilnya dan mengalikannya dengan 100 untuk memperoleh persentase. Rumus MAPE adalah sebagai berikut:




$$MAPE = \frac{1}{n} \sum_{t=1}^n \frac{|Y_t - \hat{Y}_t|}{|Y_t|} \quad (6)$$

## 2.1.4. Klasifikasi

### 2.1.4.1. Support Vector Machine (SVM)

Algoritma *Support Vector Machine* melakukan klasifikasi dengan mencari *hyperplane* optimal yang memisahkan kelas dengan margin maksimum. Proses ini ditentukan oleh data terluar (*support vector*). Meskipun umumnya digunakan pada data yang dapat dipisahkan secara linear, SVM juga mampu menangani kasus non-linear melalui transformasi ke ruang berdimensi lebih tinggi.




**Gambar 2.** Algoritma *Support Vector Machine*

### 2.1.4.2. Random Forest (RF)

*Random Forest* merupakan algoritma klasifikasi yang menggabungkan beberapa pohon keputusan. Penggabungan beberapa pohon keputusan menurunkan konsep antara varians, bias, dan mengurangi *overfitting*. Dalam klasifikasi, RF menggunakan Indeks Gini untuk menentukan pemisahan *node* pada cabang pohon keputusan. Indeks Gini dihitung berdasarkan kelas dan probabilitas, kemudian digunakan untuk menentukan cabang yang paling mungkin terjadi sehingga menghasilkan prediksi dari algoritma RF.






**Gambar 3.** Algoritma *Random Forest*

#### 2.1.4.3. *Histogram-based Gradient Boosting (HGB)*

*Histogram-based Gradient Boosting* adalah algoritma klasifikasi yang melatih model *gradient boosting* secara efisien dengan mendiskretisasi fitur kontinu ke dalam *bin*. Histogram yang terbentuk digunakan untuk menghitung kumulatif gradien dan jumlah data pada tiap *bin* guna menentukan titik *split* terbaik. *Ensemble* kemudian dibangun secara bertahap, yaitu setiap pohon memperbaiki kesalahan sebelumnya dengan meminimalkan fungsi *loss* melalui arah *negative gradient*.



**Gambar 4.** Algoritma Histogram-based Gradient Boosting

#### 2.1.4.4. Evaluasi Model

*Confusion matrix* digunakan untuk membandingkan kelas hasil prediksi dengan kelas data aktual.

**Tabel 2.** *Confusion Matrix*

|                |              | Kelas Sebenarnya |              |
|----------------|--------------|------------------|--------------|
|                |              | <i>True</i>      | <i>False</i> |
| Kelas Prediksi | <i>True</i>  | TP               | FP           |
|                | <i>False</i> | FN               | TN           |

Keterangan:

*True Positive* (TP) : kejadian positif yang diprediksi benar positif

*True Negative* (TN) : kejadian negatif yang diprediksi benar negatif

*False Positive* (FP) : kejadian negatif, tetapi diprediksi positif

*False Negative* (FN) : kejadian positif, tetapi diprediksi negatif

Performa kinerja model dapat diukur berdasarkan *accuracy* dan *F1-Score*. Akurasi menunjukkan persentase data uji yang dapat diklasifikasikan dengan benar oleh model. Nilai *F1-Score* bergantung pada *precision* dan *recall*. Rumus *accuracy* dan *F1-Score* adalah sebagai berikut:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (7)$$

$$Precision = \frac{TP}{TP + FP} \quad (8)$$

$$Recall = \frac{TP}{TP + FN} \quad (9)$$

$$F1 - Score = 2 \times \frac{recall \times precision}{recall + precision} \quad (10)$$




DIKTISA INTEK  
BERDAMPAK



## 2.2. Hasil Analisis

### 2.2.1. Klasterisasi

Sebelum klasterisasi, dilakukan analisis korelasi antarvariabel untuk melihat hubungan antara indikator ekonomi dan pendidikan.



**Gambar 5.** *Heatmap* Korelasi Antarvariabel


Berdasarkan Gambar 5, variabel persentase NEET, TPAK, TPT, melek aksara, dan PDRB memiliki hubungan yang saling terkait, baik dalam arah positif maupun negatif. Hal ini menunjukkan bahwa kondisi ekonomi dan pendidikan memang saling memengaruhi persentase NEET.

Penelitian ini menerapkan tiga metode klasterisasi, yaitu *K-Means*, *Agglomerative*, dan *DBSCAN*. Pada tahap *pre-processing*, dilakukan *Power Transformer* dengan metode *Yeo-Johnson* untuk mengurangi *skewness* serta *Robust Scaler* untuk meminimalkan pengaruh *outlier* pada variabel persentase NEET, TPAK, PDRB, dan melek aksara

Tabel 3. Metrik Evaluasi Metode Klasterisasi

| Metode               | Jumlah<br>Klaster<br>Terbaik    | <i>Silhouette<br/>Score</i> | <i>Davied-Bouldin<br/>Index (DBI)</i> | <i>Calinski-Harabasz<br/>Index (CHI)</i> |
|----------------------|---------------------------------|-----------------------------|---------------------------------------|------------------------------------------|
| <i>K-Means</i>       | 2                               | 0,713                       | 0,487                                 | 52,321                                   |
| <i>Agglomerative</i> | 2                               | 0,713                       | 0,487                                 | 52,321                                   |
| DBSCAN               | 2 klaster<br>dan 1 <i>noise</i> | 0,272                       | 1,236                                 | 10,182                                   |

Berdasarkan Tabel 3, metode *K-Means* dan *Agglomerative Clustering* menghasilkan dua klaster dengan performa yang sama. Berdasarkan metrik evaluasinya, kedua metode memiliki performa yang lebih baik dibandingkan dengan DBSCAN. Namun, dalam kasus ini, *Agglomerative Clustering* lebih sesuai karena jumlah data tidak terlalu besar dan variabel yang digunakan saling berkaitan sehingga struktur hierarki antarwilayah dapat terlihat lebih jelas. Pendekatan ini memberikan nilai tambah dengan memperlihatkan tingkat kedekatan antarprovinsi secara bertahap yang relevan untuk analisis kebijakan wilayah.




Gambar 6. Radar Chart Hasil Klasterisasi Ekonomi dan Pendidikan

Gambar 6 menunjukkan dua klaster optimal dari *Agglomerative Clustering*. Klaster Ekonomi dan Pendidikan Stabil berisi 35 provinsi dengan PDRB dan TPT relatif tinggi, tetapi persentase NEET, TPAK, dan melek aksara lebih rendah. Kondisi ini

menggambarkan wilayah berdaya ekonomi kuat, tetapi masih menghadapi pengangguran. Kluster Ekonomi dan Pendidikan Rentan mencakup tiga provinsi (Papua Pegunungan, Papua Selatan, Papua Tengah) dengan persentase NEET dan TPAK tinggi, tetapi PDRB, TPT, dan melek aksara rendah. Kondisi ini menggambarkan potensi angkatan kerja besar, tetapi rentan akibat rendahnya kualitas pendidikan dan banyak pemuda tidak bekerja atau sekolah.

### 2.2.2. Peramalan

Pada penelitian ini, dilakukan peramalan persentase NEET 2025–2027 menggunakan tiga metode, yaitu *Holt Exponential Smoothing* (HES), *Brown Exponential Smoothing* (BES), dan *Autoregressive Integrated Moving Average* (ARIMA). Ketiga metode ini digunakan karena data bersifat fluktuatif dan tidak stasioner.




**Gambar 7.** Pola Data Persentase NEET

**Tabel 4.** Metrik Evaluasi Metode Peramalan

| Metode                                                          | RMSE  | MAE   | MAPE  |
|-----------------------------------------------------------------|-------|-------|-------|
| <i>Holt Exponential Smoothing</i>                               | 1,113 | 0,960 | 0,043 |
| <i>Brown Exponential Smoothing</i>                              | 1,531 | 1,222 | 0,053 |
| <i>Autoregressive Integrated Moving Average</i> (ARIMA) (1,2,0) | 1,462 | 1,021 | 0,046 |

Berdasarkan Tabel 4, metode terbaik untuk meramalkan persentase NEET 2025–2027 adalah *Holt Exponential Smoothing* karena memiliki nilai galat (RMSE, MAE, dan MAPE) terkecil sehingga menghasilkan prediksi dengan kesalahan minimal.



**Gambar 8.** Data Asli dan Hasil Peramalan

Berdasarkan hasil peramalan metode HES (Gambar 8), persentase NEET 2025–2027 diproyeksikan sedikit meningkat dibandingkan tahun 2024. Garis ramalan yang berada pada kisaran 21–22% menunjukkan tren naik setelah penurunan pada 2024. Area bayangan biru menggambarkan interval prediksi yang menunjukkan tingkat ketidakpastian prediksi. Nilai yang meningkat dibandingkan tahun 2024 perlu menjadi perhatian.


### 2.2.3. Klasifikasi

Berdasarkan hasil analisis klasterisasi dan peramalan, perlu diperhatikan aspek kesetaraan pendidikan dan ekonomi guna meningkatkan kesejahteraan pemuda. Analisis dapat diperdalam melalui klasifikasi bidang target pekerjaan menggunakan berbagai algoritma *machine learning*, yaitu *Support Vector Machine* (SVM), *Random Forest* (RF), dan *Histogram-based Gradient Boosting* (HGB). Sebaran bidang target pekerjaan memberikan informasi yang berguna untuk menentukan langkah analisis selanjutnya.



**DIKLAISAINTEK  
BERDAMPAK**





**Gambar 9.** Bar Chart Bidang Target Pekerjaan

Berdasarkan Gambar 9, diperoleh informasi bahwa setiap kelas pada bidang target pekerjaan tidak seimbang (*imbalance*) sehingga pada tahap *pre-processing* dilakukan penanganan ketidakseimbangan data dengan *resampling* menggunakan metode SMOTETomek (*Over-Under Sampling*). Pada algoritma SVM dan HGB, data di-*scaling* menggunakan *Standar Scaler* agar skala data bernilai sama.

Metode RF menghasilkan *F1-Score* sebesar 70%. Nilai ini lebih tinggi dibandingkan metode SVM 47% dan HGB 67%.

**Tabel 5.** Metrik Evaluasi Metode Klasifikasi

| Metode                        | <i>Accuracy</i> | <i>F1-Score</i> |
|-------------------------------|-----------------|-----------------|
| <i>Support Vector Machine</i> | 0,50            | 0,47            |
| <i>Random Forest</i>          | 0,71            | 0,70            |
| <i>Hist Gradient Boosting</i> | 0,68            | 0,67            |

Berdasarkan Tabel 5, algoritma *Random Forest* memiliki performa paling baik dibandingkan dengan dua metode lainnya. Dengan demikian, algoritma *Random Forest* adalah algoritma terbaik untuk memprediksi peluang kecocokan dengan bidang target pekerjaan.




DIKTISAINTEK  
BERDAMPAK



### 2.3. Aplikasi NEET2Next

NEET2Next adalah *platform* berbasis data yang dirancang untuk mendukung pemuda, khususnya kategori NEET, dalam bertransisi menuju kehidupan yang lebih produktif. Tujuan utamanya adalah mengurangi jumlah pemuda yang tidak bekerja, bersekolah, atau mengikuti pelatihan melalui pemanfaatan analisis klasterisasi, peramalan, dan klasifikasi. Aplikasi ini membantu individu menjelajahi peluang kerja dan pelatihan, meningkatkan potensi diri melalui kursus berbasis keterampilan pasar, dan terhubung dengan mentor berpengalaman.




Gambar 10. Tampilan *Login* Aplikasi NEET2Next



DIKTISAINTEK  
BERDAMPAK








**Gambar 11.** Beranda Aplikasi NEET2Next


Gambar 11 menunjukkan beranda aplikasi NEET2Next sebagai pusat layanan dengan fitur rekomendasi lowongan kerja, *search bar*, dan *filter*. Pengguna dapat mengakses *course* berupa artikel dan video untuk meningkatkan keterampilan serta mencoba simulasi psikotes. Pada tingkat makro, tersedia peta klasterisasi kondisi sosial-ekonomi dan pendidikan serta peramalan persentase NEET tiga tahun ke depan. Pada bagian bawah tersedia *toolbar* dengan empat ikon: beranda, prediksi bidang kerja, konsultasi mentor, dan profil pengguna.





**Gambar 12.** Tampilan Fitur Prediksi Peluang Bidang Pekerjaan Aplikasi NEET2Next

Gambar 12 menampilkan fitur utama aplikasi, yaitu prediksi peluang bidang target pekerjaan. Pengguna mengisi data pribadi dan riwayat kerja yang kemudian diproses dengan algoritma *Random Forest* untuk menghasilkan persentase kecocokan dengan bidang pekerjaan yang diinginkan dan tiga bidang pekerjaan dengan persentase kecocokan tertinggi. Hasil prediksi kemudian dihubungkan langsung dengan rekomendasi lowongan relevan dan memberikan pengalaman prediktif sekaligus praktis.



**Gambar 13.** Tampilan Fitur Konsultasi Mentor Aplikasi NEET2Next

Gambar 13 adalah tampilan fitur konsultasi mentor yang memperkuat aspek personalisasi dengan menghadirkan interaksi langsung antara pengguna dan mentor berpengalaman dalam rekrutmen, tes, maupun pengembangan diri.



**Gambar 14.** Tampilan Fitur Melamar Pekerjaan Aplikasi NEET2Next



**DIKTISAINTEK  
BERDAMPAK**



Gambar 14 menampilkan fitur melamar pekerjaan. Fitur ini menampilkan detail, seperti lokasi, status karyawan, bidang kerja, deskripsi, kualifikasi, dan nilai tambah. Di bagian bawah tersedia tombol *Simpan* untuk menyimpan lowongan serta tombol *Buat Lamaran* yang mengarahkan ke halaman pengajuan lamaran

Analisis yang lebih mendalam diperlukan untuk mengevaluasi keunggulan, keterbatasan, peluang, serta potensi ancaman yang dapat memengaruhi keberlangsungan aplikasi NEET2Next. Analisis SWOT disajikan guna memberikan pemahaman komprehensif mengenai posisi strategis aplikasi NEET2Next dalam mendukung pemuda dan pemangku kebijakan.

**Tabel 6.** SWOT Aplikasi NEET2Next

| <i><b>Strength</b></i>                                                                                                                  | <i><b>Weakness</b></i>                                                                                     |
|-----------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|
| 1. Personalisasi pengalaman dengan riwayat dan target karier sehingga rekomendasi yang diberikan lebih relevan.                         | 1. Keterbatasan variabel data karena adanya faktor kualitatif yang sulit diukur atau tidak terdokumentasi. |
| 2. Fitur pendukung: tes, wawancara, dan simulasi psikotes untuk mendukung pengembangan diri.                                            | 2. Sistem perlu pembaruan terus-menerus sesuai tren kerja.                                                 |
| 3. Akses mudah dan inklusif bagi semua lapisan masyarakat sehingga manfaatnya lebih merata.                                             |                                                                                                            |
| <i><b>Opportunities</b></i>                                                                                                             | <i><b>Threats</b></i>                                                                                      |
| 1. Inovasi unik sebagai pionir prediksi peluang kerja personal.                                                                         | 1. Risiko kebocoran dan penyalahgunaan data pribadi.                                                       |
| 2. Fleksibel untuk individu maupun pemangku kebijakan untuk analisis makro.                                                             | 2. Tuntutan inovasi berkelanjutan untuk bertahan di pasar.                                                 |
| 3. Potensi kolaborasi strategis dengan pemerintah dan lembaga untuk meningkatkan kredibilitas, jangkauan, serta keberlanjutan aplikasi. |                                                                                                            |



### 3. Penutup

NEET masih menjadi tantangan multidimensi di Indonesia yang dipengaruhi faktor sosial-ekonomi, pendidikan, akses informasi, dan kesenjangan gender. Meski persentase NEET 2024 mengalami penurunan, distribusinya belum merata antarwilayah dan kelompok sosial. Kondisi ini menuntut solusi tidak hanya reaktif, tetapi juga prediktif agar mampu mengantisipasi dinamika pasar kerja dan kebutuhan pemuda di masa depan.

Dalam kerangka tersebut, aplikasi NEET2Next hadir sebagai inovasi berbasis data dengan integrasi analisis klasterisasi, peramalan, dan klasifikasi. Aplikasi ini menawarkan rekomendasi lowongan, kursus keterampilan, simulasi psikotes, hingga konsultasi mentor sehingga dapat menjadi *platform* komprehensif bagi individu maupun pemangku kebijakan. Analisis SWOT menunjukkan kekuatan pada aspek personalisasi, aksesibilitas, dan layanan pendukung, disertai peluang besar melalui kolaborasi lintas lembaga. Namun, tantangan berupa keterbatasan data, kebutuhan pembaruan berkelanjutan, risiko keamanan informasi, serta persaingan pasar tetap perlu diantisipasi agar aplikasi ini benar-benar mampu menjadi katalisator pengurangan persentase NEET dan mendorong pembangunan inklusif di Indonesia.

### 4. Daftar Pustaka

Addini, R. R. (2025, September 6). *Dunia kerja tak lagi ramah sarjana: Fresh graduate terancam menganggur.* CNBC Indonesia. <https://www.cnbcindonesia.com/research/20250906061242-128-664615/dunia-kerja-tak-lagi-ramah-sarjana-fresh-graduate-terancam-menganggur>

Badan Pusat Statistik (2024). *Percentage of Youth (Aged 15-24 Years) Not in Education, Employment or Training (NEET) (Percent), 2024* [Dataset]. [https://www.bps.go.id/en/statistics-table/2/MTE4NiMy/percentage-of-youth--aged-15-24-years--not-in-education--employment-or-training--neet-.html?utm\\_source=chatgpt.com](https://www.bps.go.id/en/statistics-table/2/MTE4NiMy/percentage-of-youth--aged-15-24-years--not-in-education--employment-or-training--neet-.html?utm_source=chatgpt.com)

Badan Pusat Statistik. (2024). *Angka Melek Aksara Penduduk 15-24 Tahun Menurut Provinsi, 2024* [Dataset]. <https://www.bps.go.id/id/statistics->



[table/2/MTQ2MiMy/angka-melek-aksara-penduduk-15-24-tahun-menurut-provinsi.html](https://table/2/MTQ2MiMy/angka-melek-aksara-penduduk-15-24-tahun-menurut-provinsi.html)

Badan Pusat Statistik. (2024). *Laju pertumbuhan Produk Domestik Regional Bruto atas dasar harga konstan 2010 menurut provinsi (persen)* [Dataset]. <https://www.bps.go.id/id/statistics-table/3/WnpCcmNtcE1ibkF5VjFSelJHMUVhRE52WjNWSVp6MDkjMyMwMDAw/laju-pertumbuhan-produk-domestik-regional-bruto-atas-dasar-harga-konstan-2010-menurut-provinsi-persen-.html?year=2024>

Badan Pusat Statistik. (2024). *Persentase Angkatan Kerja Terhadap Penduduk Usia Kerja (TPAK) menurut Provinsi* [Dataset]. <https://www.bps.go.id/id/statistics-table/2/MjM5NiMy/persentase-angkatan-kerja-terhadap-penduduk-usia-kerja--tpak--menurut-provinsi.html>

Badan Pusat Statistik. (2024). *Tingkat Pengangguran Terbuka Menurut Provinsi (Persen), 2024* [Dataset]. <https://www.bps.go.id/id/statistics-table/2/NTQzIzI=/tingkat-pengangguran-terbuka-menurut-provinsi.html>

Bronfenbrenner, U. (1979). *The ecology of human development: Experiments by nature and design*. Harvard University Press.

Erlin, E., Desnelita, Y., Nasution, N., Suryati, L., & Zoromi, F. (2022). Dampak SMOTE terhadap Kinerja Random Forest Classifier berdasarkan Data Tidak seimbang [Impact of SMOTE on Random Forest Classifier Performance based on Imbalanced Data]. *Matrik: Jurnal Manajemen, Teknik Informatika, dan Rekayasa Komputer*, 21(3), 680. <https://doi.org/10.30812/matrik.v21i3.1726>

Ester, M., Kriegel, H. P., Sander, J., & Xu, X. (1996). A density-based algorithm for discovering clusters in large spatial databases with noise. *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD-96)*, 226–231.

Fitriyani, N. L., Syafrudin, M., Chamidah, N., Rifada, M., Susilo, H., Aydin, D., Qolbiyani, S. L., & Lee, S. W. (2025). A Novel Approach Utilizing Bagging, Histogram Gradient Boosting, and Advanced Feature Selection for Predicting the





- Onset of Cardiovascular Diseases. *Mathematics*, 13(13), 7–9.  
<https://doi.org/10.3390/math13132194>
- Han, J., Kamber, M., & Pei, J. (2011). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.
- Ikotun, A. M., Ezugwu, A. E., Abualigah, L., Abuhjaja, B., & Heming, J. (2023). K-means clustering algorithms: A Comprehensive Review, Variants Analysis, and Advances in the Era of Big Data. *Information Sciences*, 622, 178–210.  
<https://doi.org/10.1016/j.ins.2022.11.139>
- Lina, L., Rahman, A. N., & Isnurani, I. (2024). Penerapan Metode Double Exponential Smoothing dari Brown untuk Prediksi Pendapatan Minimarket. *Lebesgue: Jurnal Ilmiah Pendidikan Matematika, Matematika dan Statistika*, 5(1), 435.  
<https://doi.org/10.46306/lb.v5i1>
- Mappapa, P. L. (2025, March 14). Data Kemendikdasmen, angka putus sekolah tertinggi terjadi di SMK. *detikEdu*. <https://www.detik.com/edu/sekolah/d-7822286/data-kemendikdasmen-angka-putus-sekolah-tertinggi-terjadi-di-smk>
- Nanlohy, Y. W. A., & Loklomin, S. B. (2023). Model Autoregressive Integrated Moving Average (ARIMA) untuk Meramalkan Inflasi Indonesia. *Variance: Journal of Statistics and Its Applications*, 5(2), 202.  
<https://doi.org/10.30598/variancevol5iss2page201-208>
- Pattinasarany, I. R. I. (2024). Social class and the transition to adulthood: Not in education, employment, or training (NEET) youth in Indonesia. *Journal of Social and Political Sciences*, 7(3), 115–127. Asian Institute of Research.
- Rini, M. W., & Ananda, N. (2022). Perbandingan Metode Peramalan Menggunakan Model Time Series. *TEKINFO - Jurnal Ilmiah Teknik Industri dan Informasi*, 10(2), 94. <https://doi.org/10.31001/tekinfo.v10i2.1419>
- Rizal, R. A., Girsang, I. S., & Prasetyo, S. A. (2019). Klasifikasi Wajah Menggunakan Support Vector Machine (SVM). *REMIK (Riset dan E-Jurnal Manajemen Informatika Komputer)*, 3(2), 2. <https://doi.org/10.33395/remik.v3i2.10080>



- Suryanegara, G. A. B., Adiwijaya, & Purbolaksono, M. D. (2021). Peningkatan Hasil Klasifikasi pada Algoritma Random Forest untuk Deteksi Pasien Penderita Diabetes Menggunakan Metode Normalisasi. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 5(1), 118. <https://doi.org/10.29207/resti.v5i1.2880>
- Suryanto, A. A., & Muqtadir, A. (2019). Penerapan Metode Mean Absolute Error (MEA) dalam Algoritma Regresi Linear untuk Prediksi Produksi Padi. *SAINTEKBU: Jurnal Sains dan Teknologi*, 11(1), 79. <https://doi.org/10.32764/saintekbu.v11i1.298>
- Utami, R., & Atmojo, S. (2017). Perbandingan Metode Holt Exponential Smoothing dan Winter Exponential Smoothing untuk Peramalan Penjualan Souvenir. *Jurnal Ilmiah Teknologi Informasi Asia*, 11(2), 124. <https://doi.org/10.32815/jitika.v11i2.191>
- Utiahman, S. A., & Pratama, A. M. M. (2024). Penerapan Support Vector Machine dan Random Forest Classifier untuk Klasifikasi Tingkat Obesitas. *Jurnal Fasilkom*, 14(3), 757.
- Willy, Rini, D. P., & Samsuryadi. (2021). Perbandingan Algoritma Random Forest Classifier, Support Vector Machine dan Logistic Regression Classifier pada Masalah High Dimension (Studi Kasus: Klasifikasi Fake News). *Jurnal Media Informatika Budidarma*, 5(4), 1723. <https://doi.org/10.30865/mib.v5i4.3177>
- World Bank. (2020, November 10). *Youth opportunities project in Liberia helps young people increase their earning potential*. World Bank. <https://www.worldbank.org/en/results/2020/11/10/youth-opportunities-project-in-liberia-helps-young-people-increase-their-earning-potential>



DIKTISAINTEK  
BERDAMPAK

